中国研究生操作系统开源创新大赛

项目说明书 · 内核优化分册

作品名称：面向智能机器人的 AIOS

参赛队伍：Xenoblade

完成日期：2026 年 10 月

目 录

第 1 章 内核优化路线 **1**
1.1 内核优化：从“每个操作要付多少固定成本”入手 1
1.1.1 优化之前的总体画像 1
1.1.2 机制族清单 2
第 2 章 代码原创说明 **4**
2.0.1 提交清单 4
2.0.2 原创性与引用边界 4
第 3 章 内核优化的工程实现 **6**
3.1 内核优化的工程实现 6
3.1.1 K1 系统调用返回路径：把指令缓存刷新收敛到少数事件上 6
3.1.2 K2 地址空间操作的机械开销：三处只删冗余的改动 6
3.1.3 K3 exec 的页物化：先减少要铺的页，再把剩下的摊到一次操作上 7
3.1.4 K4 缺页的每页固定成本：页索引与内存原语 7
3.1.5 K5 顺序缺页的窗口批量物化：四步 7
3.1.6 K6 文件读路径：一次多余的拷贝、一次逐页的事务、两处冗余失效 8
3.1.7 K7 存储写回与元数据：批量粒度、页缓存容量与访问时间 8
3.1.8 K8 启动等待：固定阻塞改成带截止时间的轮询 9
第 4 章 内核优化的测试 **10**
4.1 内核优化的测试说明 10
4.1.1 本线特有的测试口径 10
4.1.2 探针与验收门 10
4.2 内核优化的测试结果 11
4.2.1 总体对照 11
4.2.2 系统调用与进程间通信 12
4.2.3 进程创建与 exec 13
4.2.4 缺页与地址空间 13
4.2.5 文件读路径 13
4.2.6 存储写回与元数据 14
4.2.7 启动时间 16
第 5 章 内核优化的难点与未完成项 **18**
5.1 内核优化中的定位方法与难点 18
5.1.1 定位方法：分段计账、标度实验与受控 A/B 18
5.1.2 系统调用返回路径：一笔 2.17 µs 的冗余刷新 18
5.1.3 进程与 exec：账目与两条决定性判据 19
5.1.4 上下文切换：归因清楚了，但没动 19
5.1.5 缺页：从“87.7% 在 prepare”到一个 $O(n^2)$ 的索引 20
5.1.6 读路径：前两条线索为什么只值 10% 20
5.1.7 其余指标的剩余固定成本 21

5.2 被数据否掉的假设 . . . 22
5.3 已经归因清楚、但本轮没有改的项 . . . 22
5.4 一条尚未定位清楚的问题 . . . 22
第 6 章 内核优化总结 **24**
6.1 内核优化总结 . . . 24

指标	Linux 5.10.4	优化前	差距
`getpid`（空系统调用）	422.5 ns	10 560 ns	25.0×
`pipe_wr`（4 KiB 往返）	4 489 ns	46 819 ns	10.4×
管道 ping-pong（含一次切换）	26.0 µs	445.7 µs	17.1×
`fork`+`exit`+`waitpid`	338.1 µs	7 497 µs	22.2×
`fork`+`execve`+`waitpid`	2 407 µs	43 537 µs	18.1×
上下文切换	10.97 µs	226.8 µs	20.7×
64 MiB 匿名首触（默认 4 KiB）	7 899 ns/页	1 302 123 ns/页	165×
ext4 `open`+`read`(1 KiB)+`close`	42 µs	10 320 µs	246×
8 MiB 顺序写 + `fsync`	790 ms	7 961 ms	10.1×
缓存命中大读（缓冲已触碰）	671.6 MB/s	374 MB/s	1.80×
缓存命中大读（每轮新缓冲）	271.1 MB/s	50.2 MB/s	5.40×
内存 `memcpy` / 顺序读带宽	1.024 / 1.488 GB/s	0.984 / 1.420 GB/s	1.04× / 1.05×
端到端冷启动（`bootm`→提示符）	33.2 s	13.21 s	我方更快 2.5×

表 1: 优化起点的横向对照。前九行是“每个操作都要付的固定成本”，差距都在一个数量级以上；末四行是带宽型或总量型指标，本来就不落后

第 1 章　内核优化路线

1.1　内核优化：从“每个操作要付多少固定成本”入手

内核层的工作目标很具体：项目立项时的横向对比显示，同一块板、同一份静态 riscv64 ELF 上，StarryOS 在**每次系统调用、每次进程创建、每次缺页、每次文件读**这些固定开销上 比 Linux 基线贵一到两个数量级，而在内存带宽、大块顺序写、冷启动这些**带宽或总量型** 指标上并不落后。因此这一阶段不做功能补全，而是沿着“把每次都要付的固定成本降下来”这一条主线，逐个热点做归因、改机制、再实测。

1.1.1　优化之前的总体画像

优化起点（2026-10-04 的 `ours` 基线镜像）与 Linux 的对照如下。这张表决定了优化的 优先级：凡是差距在一个数量级以上的，都是“每个操作都要付的固定成本”；凡是基本持平 的，都是带宽型或总量型指标。

这张表给出三点判断，后文的取舍都围绕它们展开：

1. **系统调用入口是最大的单点**。一个什么都不做的 `getpid` 要 10.56 µs，是同板 Linux 的 25 倍。它的处理体只取一个已在内存里的进程号，所以这 10.56 µs 几乎全部是 “进入内核、返回用户态”这条固定路径。
2. **调度与进程生命周期的固定开销排在第二**。`fork`+`exit` 22 倍、上下文切换 20 倍、管道往返 17 倍、exec 18 倍，全都在同一个量级上；这条链路要拆成“页表复制 / 首次入队 / 子进程析构 / 每次切换”四段分别处理。
3. **内存的“每页固定成本”比内存带宽问题严重得多**。 64 MiB 首触慢 165 倍，而 `memcpy` 带宽只差 4%。据此判定，差距来自每页一次事务的簿记开销；同板带宽类指标两侧接近。

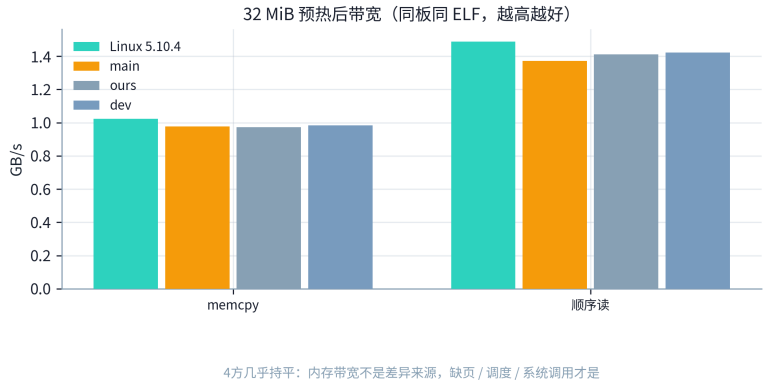


图 1: 同板对照下的内存带宽。`memcpy` 与顺序读在各方之间只差几个百分点——它说明本板的差距不在内存子系统，而在“每次操作要付多少固定成本”

编号	优化族	族内具体改动
K1	系统调用返回路径	把“每次返回用户态都刷指令缓存”收敛到用户映像可能陈旧的少数事件上（`exec`、`PROT_EXEC`、切换地址空间）
K2	地址空间操作的机械开销	① 取消每叶的第二次页表走查；② 发布去重由 $O(n^2)$ 改 $O(n \log n)$；③ 地址空间退休不再逐页摘除
K3	exec 的页物化	① static-PIE 只物化带写权限的段，只读段改按需缺页；② 文件后端按连续 run 批量 pin 与域预留
K4	缺页的每页固定成本	① COW 页索引不再每次全量重建；② 内存操作从逐字节改字长
K5	顺序缺页的窗口批量物化	① 严格升序的私有匿名缺页按 64 KiB 窗口整段物化；② 窗口旋钮 + 短流爬坡；③ 窗内帧整块分配 + 子租约；④ 窗内索引按 run 批量
K6	文件读路径	① pin 住页缓存页直接拷给调用方；② 用户内存准备整段化；③ 延迟失效不再逐页刷 TLB；④ 修复复用帧被旧墓碑遮蔽的身份查询
K7	存储写回与元数据	① 脏页按连续 run 合并写回；② 页缓存上限 512 → 4096 页；③ `close` 按 `relatime` 处理访问时间
K8	启动等待	把启动期固定 2 s 的 DHCP 阻塞等待改成带截止时间的轮询

表 2: 内核改动按机制族归并：族内各条作用在同一条路径上、收益相互叠加，故按族给出对照数据。工程实现见 3.1 节，实测见 4.2 节，提交记录见 第 2 章

还有两条“看起来很小、实际很贵”的发现：ext4 上每次 `open+read+close` 要付一次 约 10 ms 的同步日志提交（Linux 只在内存里改访问时间），以及启动期一个固定 2 s 的 DHCP 阻塞等待。

1.1.2　机制族清单

下表是本阶段实际落地的改动。这里按**机制族**归并，而不是按提交逐条罗列：同一族里的 几条改动作用在同一个数据结构或同一条路径上，彼此耦合、收益也相互叠加，拆开单看 容易重复计数。八族改动都满足两个约束：**机制上的改动都独立实现**，并且**每一族都有“优化前/优化后”的同板 A/B 数据**。

除内核之外，系统层还有两条工作线，其路线同样在本章给出：一条把 SG2002 的板级外设接通、 并把“改内核—上板—取数”做成可重复执行的通道；另一条把厂商固件里那颗 RISC-V

实时小核 从“存在但未被使用”变成可管理的第二个可编程执行体，并由它接管底盘串口这条 硬实时链路。三者共用同一套评测口径与同一块板。

编号	优化族	提交与关键验证
K1	系统调用返回路径	`0a627ecb7`；宿主单测 + 板端全项 + 78 轮 `exec` 压力
K2	地址空间操作的机械开销	`10e67ae8d`（取消每叶第二次走查 + 去重复杂度）、`5491b9956`（退休不再逐页）；`try_clone` 1 747 → 1 528 µs，退休 3.57 → 0.41 ms
K3	exec 的页物化	`e13b6b962`（只读段直映）、`f5d357d4a`（按 run 批量 pin + 只物化可写段）；exec 内核侧 32 → 4.5 ms，缺页数 200 → 79 页/次
K4	缺页的每页固定成本	`130a98059`（页索引）、`760ef6d08`（字长内存操作，含一处未定义行为修复）；64 MiB 首触 8.3×，清零 6.8×
K5	顺序缺页的窗口批量物化	`bcd2d4e71`（窗口预取）、`371ffc0dd`（帧整块 + 子租约）、`792ffed5f`（索引按 run 批量，配套正确性修复 `dd8f6f0e1`）；防膨胀 1.00×/0.96×，块命中率 99.97%
K6	文件读路径	`cc56cd47e`（pin 直拷）、`11146c8a6`（整段物化）、`584b07fa7`（整段快路径 + 注册表 O(n) 化）、`c16994af2`（不再逐页刷 TLB）；三种分块校验和一致，TLB 自检 0 不匹配
K7	存储写回与元数据	`1db22090c`（写回批量）、`29e264fd0`（页缓存上限）、`a3cd50ece`（访问时间策略）；`fsync` 7.96 → 0.93 s，写吞吐 17.6×
K8	启动等待	`ce9b42a92`；用户态标记 −1.2 s

表 3: 内核改动按机制族归并后的提交清单。族内的多个提交作用在同一条路径上，单看任何一个都低估了整族的收益

第 2 章　代码原创说明

本节说明本项目在内核侧所提交改动的归属与核对入口。总的立场是：**上游已有的能力不主张为新增贡献，本分支的改动都能落到一个具体提交上，且都带同板 A/B 数据**。

2.0.1　提交清单

下表按第 2.2 节给出的机制族（K1–K8）列出对应提交与关键验证。同一族可能落在多个提交上：它们作用在同一条路径上、收益相互叠加，因此按族给出对照数据，逐提交细节见仓库历史。

2.0.2　原创性与引用边界

三条约束保证这些改动可以被独立核对。

第一，**每条结论都能落到一个提交上**，并且都带“优化前/优化后”的同板 A/B 数据；数据取法与口径见 4.2 节。

第二，**机制上的改动在本分支独立实现**，且都遵循同一条约束：不改变对外可观察的语义。其中三处确实动到了对外语义——返回用户态时的指令缓存刷新策略、延迟失效路径的 TLB 失效时机、文件的访问时间策略——都额外做了专项自检（多二进制 `exec` 压力、固定地址反复映射的 TLB 一致性探针、多分块读校验和比对），并保留运行期回退开关。

第三，**与上游的关系是增量而非替换**。本分支的基线是 TGOSKits 的 `board-aka-00-sg2002` 配置；改动以补丁形式叠加，不改变其它板卡与应用的行为。上游已有的能力——TPU 与 ION、USB

主机栈、串口以及板卡用例——在本项目中原样复用，不在本节 主张为新增贡献；本节与 4.2 节列出的收益，都只针对本分支明确改动的部分。

第 3 章　内核优化的工程实现

3.1　内核优化的工程实现

本节按机制族（K1–K8）说明每处改动**改了什么、怎么改**；每族对应的实测数据放在 4.2 节，定位过程与被否掉的替代方案放在 5.1 节。这样安排是为了让“改法”与“证据”各归其位：本节每一条都能在前文的机制族清单里找到对应的提交与验证。

3.1.1　K1 系统调用返回路径：把指令缓存刷新收敛到少数事件上

问题出在返回用户态的路径上：内核在**每一次**返回用户态之前都执行一次指令缓存失效（riscv64 的 `fence.i`）。它在语义上只在“用户映像的代码字节可能陈旧”时才需要，而内核 本来就已经在两处正确的位置刷：把页变成可执行时（`PageObject::prepare_executable_mapping` 覆盖了全部 11 条装页表的路径）与 ptrace 改写正文后（`AddrSpace::sync_modified_text`）。

改法是把默认行为反转为“不刷”，只在四类事件上刷一次：`execve` 装载新映像、`mmap` 或 `mprotect` 把一段内存变成可执行、切换到另一个地址空间，以及显式写 `/proc/icache_flush`。 最后一项同时是运行期回退旋钮，写 1 即恢复旧行为。因为这条动的是对外语义，验证上做了 三层：宿主单测、板端全项 harness、以及 78 轮多二进制 `exec` 压力（反复装载不同的可执行 文件并校验每次输出）。

该族的本质是把“每次返回用户态都要付一次”的固定成本，换成“仅在映像发生变化时才付一次” 的事件成本；事件边界由装页表路径与 ptrace 入口这两个既有钩子保证，因此省下的是每个 系统调用都能观测到的固定开销。

3.1.2　K2 地址空间操作的机械开销：三处只删冗余的改动

`fork` 与子进程析构两栏的时间与内存带宽无关，其构成为同一类重复：本该一次做完的事 被逐项做了，本该 O(n log n) 的事写成了 $O(n^2)$。三处改动属于同一族，均只删冗余、 不改语义。

取消每个叶子的第二次页表走查：`occupied_leaf_records()` 本来已经拿到页表遍历时的 原始 PTE，却对每个叶子再调一次 `pt.query()` 复核；改成复用遍历结果后，单个叶子的克隆 成本从 99 μs 降到 82 μs。

所有者发布去重由 $O(n^2)$ 改为 O(n log n)：`publish_prepared_pte_owners()` 用线性 `Vec::contains` 检测重复键，而批量填充一次要发布几百个所有者；换成 `BTreeSet` 后这段从 120 μs 降到 99 μs。两处合计让 `try_clone` 从 1 747 μs 降到 1 528 μs、`fork()` 系统 调用从 4 739 μs 降到 4 418 μs。

地址空间退休不再逐页摘除：子进程退出时要退休整个地址空间，原实现逐页 `unmap`，每次 都要走查页表、再走查一次页表、更新地址空间账目；改成整段交给批量路径后，子地址空间 退休从 3.57 ms 降到 0.41 ms（8.7×）。这 3.2 ms 不在 `fork_exit` 的墙钟里（它由内存 回收线程异步完成），但直接减少了每次 fork+exit 的 CPU 占用。

三处改动都不改变任何对外可见的语义，只去掉重复的工作与平方级的写法，因此收益直接落在 “每次 fork 与退出一共要跑多少条指令”上，与内存带宽无关。

3.1.3　K3 exec 的页物化：先减少要铺的页，再把剩下的摊到一次操作上

execve 的内核侧成本优化前是 32.3 ms，分段后 88% 落在一处：static-PIE 把每个 PT_LOAD 段整段物化。往物化里挖又得到三条否证——文件后端的分段计数全程为 0（说明段映射走的是 COW 而不是共享文件映射）、一次 51 轮 exec 压力前后的块层读数增量为零（说明 exec 完全不读 SD 卡）——因此每页的成本是“一次帧分配 + 三次 4 KiB 拷贝 + 页对象与索引 + 装页表”。

据此做了三刀：第一，**只物化带写权限的段**。重定位只写 .got / .data.rel.ro / .bss，只读段完全可以按需缺页，于是只整段物化 PT_LOAD 里带 WRITE 的那些。第二，**按连续 run 批量处理**：物化时把“逐页一次 io_lock”改成整段一次 pin_pages_run、整段一次域锁预留，并把每段一次的全表清理收成一次。第三，**单页缺页不再每次跑 O(表长) 的清理**：改成“命中 陈旧条目才清 + 每 512 次兜底”。

结果是 exec_load 从 31.7 ms 降到 4.5 ms（其中 exec_populate 从 28.3 ms 降到 1.2 ms），exec 内部的缺页数从约 200 页/次降到 79 页/次，fork_exec_exit 从 43 537 µs 降到 22359 µs。值得注意的是这一族的两条改动方向相反：第一条**减少要铺的页**，第二条**把剩下的页摊到一次批量操作上**，两者叠加才拿到全部收益。

3.1.4　K4 缺页的每页固定成本：页索引与内存原语

缺页分段显示 87.7% 的时间在 prepare，而 prepare 里 58% 在 pending_insert——COW 页索引的插入。原因是该索引既在每次插入时扫描整个索引统计存活条目（每项一次原子读），又用有序 Vec 做插入，两者叠加成 $O(n^2)$，成本随区域线性膨胀。改法是纯数据结构层面的：有富余容量时直接插入、跳过存活计数；已过期的弱引用条目改在容量增长路径上摊还清理；重叠检查只对存活条目生效。

同一族里还有一处与数据结构无关的改动：内核导出的 memcpy/memmove/memset/memcmp 全是逐字节 for 循环，而内核里所有清零与拷贝都链接到它们。改成 8 字节对齐 + u64 批量 + 尾部补齐（memcpy/memcmp 只在源目对齐一致时走字长），顺带修掉一处真实的未定义行为：memmove 的反向路径在 i == 0 时先算 ptr.add(i - 1)，地址下溢本身是 UB，编译器据此 做的优化会让用户进程偶发丢输出并以 SIGSEGV 退出。

两处改动的共同点是把随区域大小增长的簿记压回与页数同阶：索引侧去掉平方级的扫描与计数，内存原语侧去掉逐字节循环，两者都属于“每次操作都要付”的固定成本。

3.1.5　K5 顺序缺页的窗口批量物化：四步

前两族之后，“每页一次事务”仍是主要成本。动手之前先量上界：同一块板上，逐页缺页是 144 700 ns/页，而一次 mmap(MAP_POPULATE) 走既有的整段物化原语只要 62 800 ns/页—— 真正贵的是每页一次事务，不是内存带宽。据此实现这一族，共四步。

第一步，**按 64 KiB 窗口整段物化**，判据刻意保守：只在严格升序（本次缺页页正好接在上一次 窗口末尾）时预取，跨步与随机访问完全不命中；只对私有匿名且策略叶子为 4 KiB 的 VMA 生效，文件与共享后端语义不变，MADV_HUGEPAGE 的 VMA 也不会被提前铺上 4 KiB 页表。

第二步，**窗口大小做成运行期旋钮并加短流爬坡**。窗口大小是“按窗付的固定开销”与“预取深度”的权衡，因此没有拍常数，而是加了 /proc/fault_around（写页数，0 表示关闭）再扫描

定值，取 64 页（256 KiB）。固定大窗口的代价是“只顺序碰两页的程序也要付整窗内存”，因此又加了 爬坡：连续命中第 n 次才用 8/16/32/64 页。

第三步，**窗内帧整块分配 + 子租约**：连续未映射的匿名段先按“块大小阶梯”64→32→16→8→4→2 页尝试一次分配一整块，再用 `FrameLease::sublease` 把它切成 4 KiB 子租约，每个页对象拿 一个；拿不到连续块就逐页退回。整块命中率 99.97%，索引插入落在末尾的比例从 21% 升到 56%， 平均每次插入搬移的条目数从 102–115 降到 24。

第四步，**窗内索引按 run 批量登记**：既然一窗的物理帧连续，就把整窗的插入合并成“一次定位
1. 一次整段搬移“。这一步值得单独记一笔，因为第一版实现曾让板子在启动时硬挂（详见

5.1 节）；重做后的设计是三条：整段插入全有或全无、遇到空洞或区间内墓碑就退回逐页 登记、容量按整段预留以免在 IRQ 关闭的临界区里分配内存。

这一族把“每页一次事务”换成“每窗一次事务”：固定的按页开销被摊到 64 页一窗上，命中一次 即可覆盖整窗；判据刻意保守（严格升序、私有匿名、4 KiB 叶），跨步与随机访问的行为与 优化前一致。

3.1.6　K6 文件读路径：一次多余的拷贝、一次逐页的事务、两处冗余失效

读路径的四条改动分别去掉四件冗余。

去掉暂存中转：缓存命中时原实现要把页内容先拷进一个暂存页，出了页缓存索引锁再拷给调用方；中间那次拷贝只是为了“拷给用户前必须放锁”。改成 pin 住页缓存页 → 出锁 → 用该帧 的内核直接映射直接拷给调用方 → 放下钉子。

用户内存准备整段化：riscv64 上没有可用的硬件用户访问探测指令，内核此前每次用户访问 都要逐页跑完整的缺页事务；改成“整段已映射”快路径，再进一步把用户内存准备改成整段物化 一次（内部按 VMA 分段并收进一次变更事务，任何一步不成立就回退到逐页循环）。

延迟失效路径不再逐页刷 TLB：四个后端的 `unmap_range` 都调逐页摘除，而它内部会每一页做一次本地 TLB 失效；但调用方已经进入延迟失效守卫并对整段登记过一次失效、提交时统一 发布，逐页那次是纯冗余。

修复复用帧被旧墓碑遮蔽的身份查询：页索引里已释放帧会留下过期弱引用条目，而重分配的帧 会插到同址墓碑之前，于是查询命中死墓碑、返回“无此身份”，明明有活主人却让 fork/COW 走错 分支。改成自该位置向前扫过所有仍包含该物理地址的条目、返回第一个活主人。

四条改动去掉的都是“同一份数据被处理两次”或“同一段区间被登记两次”的冗余，缓存一致性 协议与对外可见语义均未改变，因此收益可以在不改变行为的前提下取得。

3.1.7　K7 存储写回与元数据：批量粒度、页缓存容量与访问时间

三处改动作用在同一条写回路径上：一处改每次写多大的块，一处改能攒多少脏页，一处去掉 `close` 里的同步提交。

脏页按连续 run 批量写回：写回快照拿到的本来就是连续的脏页，但回写实现仍然每页一次后端写——8 MiB 就是 2 048 次 4 KiB 写。改成把连续脏页合并成一次写，并把单次回写的批量上限从 16 页提到 64 页（256 KiB，回写期间的额外内存仍是常数级）。

页缓存上限 512 → 4096 页：8 MiB 档顺序写吞吐只有 2.41 MiB/s 的原因是页缓存上限只有 2 MiB，写满就要立刻回收、于是本地同步回写；把上限提到 16 MiB 后，写只落页缓存。

`close` 不再做同步元数据提交：文件对象析构时若句柄被读过（0 字节 `read()` 也算）就会更新访问时间，而 ext4 的元数据更新末尾直接做一次同步日志提交——在这块 SD 卡上约 10 ms。改成按 Linux 语义处理：`noatime` 不写、`strictatime` 照旧每次写，其余按默认的 `relatime`（每个文件每 24 小时至多写一次）。判定必须用**单调时钟**而不是墙上时钟：本板没有 RTC 与 NTP，`date` 显示 1970 年，用墙上时钟套 `relatime` 判据会永远判成“已过期”、退化成每次都写。

三处改动作用在同一条写回路径的不同环节：提高单次批量、放宽攒脏页的上限、去掉 `close` 里的同步提交。前两处改变的是每落一次盘要付几次固定开销，第三处去掉的是一次与数据量无关的 10 ms 级同步日志提交。

3.1.8　K8 启动等待：固定阻塞改成带截止时间的轮询

优化前，网络初始化里有一段固定 2 s 的阻塞等待（等设备就绪），无论设备是否已经就绪都要等满。改成带截止时间的轮询（上限 300 ms，一旦就绪立即继续）之后，上电到用户态标记从 10.81 s 降到 9.61 s、到 shell 可交互从 12.3 s 降到 10.8 s。启动路径上其余几块静默时间（USB 探测、无线固件加载、ext4 挂载）都牵动设备初始化的顺序与超时语义，本轮没有动，原因写在 5.1 节。

这一族说明启动路径上的固定阻塞属于“无论设备是否就绪都要等满”的成本；换成带截止时间的 轮询后，等待时间只与设备真实就绪的时刻相关，设备异常时的兜底窗口仍由截止时间上限保证。

项	内容
板卡	AKA-00-SG2002（LicheeRV Nano 血统），CPU 为 C906（riscv64，单应用核），内存 236 MiB
对照系统	厂商 Linux 5.10.4，卡上 `linux.sd`，同板同卡同一次上电周期内交替启动
用户态	同一份静态链接 riscv64 ELF。所有探针都是自研 C 程序，两侧编译同一份源码
计时	板端 `rdtime`（时基 1 MHz）+ 主机侧串口逐行时间戳；微基准取 20–100 轮中位
口径	每个指标三列：Linux 实测／优化之前／优化之后

表 4: 内核优化的评测平台与对照口径

第 4 章　内核优化的测试

4.1　内核优化的测试说明

4.1.1　本线特有的测试口径

全篇统一的评测口径（同一块板、同一份符合 Linux ABI 的静态可执行文件、两侧各测一次、未测项显式标注）已在“测试说明”中给出，本节不重复；内核这条线在此基础上另有三条 特有约定，因为它的对照组是“优化前/优化后”，而不同次上电之间的读数本身会漂移。

三条特有约定如下：

1. **冷启动受控 A/B**。内核“优化前/后”的对比尽量在**同一次上电、同一份探针、交替顺序** 下做（例如两两交替各测两遍取均值），以抵消“启动后第一次大分配明显更快”这类时间漂移。
2. **探针本身有代价**。 热路径上的分段计时是每次系统调用多 12 次取时间戳，实测平白增加 约 1.2 μs。凡是“优化前/后”的对照数字，探针都已撤掉；带探针的中间过程只在归因时出现，并注明口径。
3. **分段计账取快照之差**。 内核侧的分段数字由 `/proc/fault_attrib` 的计数器给出，取 “工作负载前后的快照之差”折算为每次调用的平均值；该口径只反映被测量路径自身，不含探针与被测负载之外的干扰。

4.1.2　探针与验收门

每一处改动上线前都过同一组门：

板端跑一组微基准（两侧同一份命令）：

```
# StarryOS 侧（登录后的 shell）
cd /root/probes
./syscost2                          # 系统调用入口
./sp2                               # 进程创建与 exec
./faultcost 64                      # 64 MiB 首触
./read_syscall /bin/busybox 1 100
./rp1 && ./rp2                      # warm/fresh 读与三段拆解
./mmc                               # TLB 一致性自检
cat /proc/fault_attrib              # 内核侧分段（读前读后各取一次，相减即"每次调用"）
```

探针	测什么	对应的优化族
`syscost2`	九个系统调用的单次开销（含 `invalid_syscall` 对照）	K1 系统调用返回路径
`sa1`	返回路径的开关分段（单步 / ptrace / seccomp / trace）	K1
`sp2`	`fork`+`exit`+`waitpid` 与 `fork`+`execve`+`waitpid` 的墙钟	K2、K3
`fk1`/`fk2`	`fork` 内部分段（页表复制 / 首次入队 / 建线程）	K2
`faultcost`	匿名首触成本 vs 区域大小（1/4/16/64 MiB）	K4、K5
`faultattrib`	缺页的 plan/prepare/apply/TLB 分段	K4、K5
`popcost`	逐页缺页与整段物化的对照（动手前的上界实验）	K5
`touch64`	冷启动 64 MiB 首触单点（受控 A/B 口径）	K5
`bloat`	预取窗口的膨胀验证（短流 / 跨步 / 随机 / `MADV_DONTNEED`）	K5
`cowtest`	`fork` 后逐页改写父子各自正确、`MAP_POPULATE` 写读校验	K5
`read_bench`	不同缓冲大小下的读吞吐	K6
`read_syscall`	`open`+`read`+`close` 的分档中位耗时	K6、K7
`rp1`/`rp2`	warm/fresh 缓冲读，以及 `mmap`/读/`munmap` 三段拆解	K5、K6
`mmc`	TLB 一致性自检（固定地址反复映射-填-拆除-再映射）	K6
`block-rw-bench`	ext4 顺序写与 `fsync`（多档位）	K7
`/proc/fault_attrib`	内核侧分段计数、索引插入位置、回收队列长度	K2、K4、K5

表 5: 本项目的探针清单。`/proc/fault_attrib` 是内核侧计数出口，所有分段数字都由“工作负载前后快照之差”取得

4.2　内核优化的测试结果

4.2.1　总体对照

按判定分三档读这张表。**已反超**的是 8 MiB 页缓存顺序写（42.43 MiB/s 对 34 MiB/s）；**持平或接近**的是 8 MiB 写 + `fsync`（931 ms 对 790 ms，1.18 倍）、缓存命中读（warm 474 MB/s 对 671.6 MB/s）与空系统调用（1631 ns 对 422.5 ns， 3.9 倍）；**仍有差距**的是上下文切换（220.4 µs 对 10.97 µs）、管道往返（421.1 µs 对 26 µs）、每轮新缓冲的缓存命中读（62.8 MB/s 对 271.1 MB/s）与 ext4 `open`+`read`+`close`（454 µs 对 42 µs，10.8 倍）。三档的成因与下一步改法分别写在 5.1 节 的对应小节，本节余下部分给出各档的逐项数据。

层	判据	适用族
宿主单测	文件系统与内存相关 crate 的宿主回归全绿（内核 crate 收尾时 261 项）	全部
板端功能	标准 harness 全项 + 功能用例（`ls`/`head`/`grep`/`sh -c`/退出码）	全部
数据正确性	同一文件多种分块读的校验和一致，且与主机侧直接导出的文件逐字节相同	K3、K6
内存不泄漏	mmap/touch/munmap 反复折腾后可用内存稳定；预取窗口另有膨胀验证	K5
一致性	TLB 一致性自检不匹配页数为 0（改 TLB 语义的改动必须跑）	K6
压力	多二进制 `exec` 压力、`fork`/`exec` 风暴、泄漏检查与调度探针全过	K1、K2
可回退	动语义的改动都留运行期回退开关（`/proc/icache_flush`、`/proc/fault_around`）	K1、K5

表 6: 验收门。凡改动动到对外语义（指令缓存、TLB、访问时间、地址空间退休），都额外做了对应的专项自检

指标	Linux	优化前	优化后	优化后/ Linux
`getpid`（空系统调用）	422.5 ns	10560 ns	1631 ns	3.9×
`pipe_wr`（4 KiB 往返）	4489.2 ns	46819 ns	12576 ns	2.8×
管道 ping-pong	26 µs	445.7 µs	421.1 µs	16.2×
`fork`+`exit`+`waitpid`	338.1 µs	7497 µs	6461 µs	19.1×
`fork`+`execve`+`waitpid`	2407 µs	43537 µs	22359 µs	9.3×
上下文切换	10.97 µs	226.8 µs	220.4 µs	20.1×
双线程 `sched_yield` 交接	6.9 µs	171 µs	112.5 µs	16.3×
64 MiB 匿名首触（默认 4 KiB）	7899 ns/页	1302123 ns/页	44120 ns/页	5.6×
64 MiB 首触（显式大页）	5683 ns/页	22216 ns/页	8014 ns/页	1.41×
ext4 `open`+`read`(1 KiB)+`close`	42 µs	10320 µs	454 µs	10.8×
8 MiB 顺序写 + `fsync`	790 ms	7961 ms	931 ms	1.18×
8 MiB 页缓存顺序写	34 MiB/s	2.41 MiB/s	42.43 MiB/s	我方更快
缓存命中读（warm）	671.6 MB/s	374 MB/s	474 MB/s	1.42×
缓存命中读（fresh）	271.1 MB/s	50.2 MB/s	62.8 MB/s	4.32×
单次大读 803 KB	277.2 MB/s	60.9 MB/s	76.2 MB/s	3.64×
冷启动到可交互 shell	33.2 s †	12.3 s	10.8 s	我方更快

表 7: 内核优化的总体结果。Linux 列为同板实测；“优化后/Linux”小于 1 表示本侧更快。上下文切换与管道往返本轮只做了归因、未改行为，故仍落后一个数量级（见 5.1 节）；† 末行两侧的启动锚点不同，只作量级参考，口径见 4.2.7 节

4.2.2　系统调用与进程间通信

`getpid` 从 25.0 倍收到 3.9 倍、`pipe_wr` 从 10.4 倍收到 2.8 倍， `sched_yield` 交接下降约三分之一。有两个口径必须写明：其一，带探针时会低估收益——同一镜像 在带 5 个系统调用探针时 `getpid`

指标	Linux 5.10.4	优化前	优化后
`getpid`（空系统调用）	422.5 ns	10560 ns	1631 ns
`pipe_wr`（4 KiB 往返）	4489.2 ns	46819 ns	12576 ns
双线程 `sched_yield` 交接	6.9 µs	171 µs	112.5 µs
管道 ping-pong	26 µs	445.7 µs	421.1 µs
上下文切换	10.97 µs	226.8 µs	220.4 µs
`memcpy` / 顺序读带宽	1.024 / 1.488 GB/s	0.984 / 1.420 GB/s	0.981 / 1.428 GB/s

表 8: 返回路径瘦身前后的对照。前三行是“调用体很轻”的指标，收益最直接；后三行主要由调度与内存主导，与归因一致

指标	Linux 5.10.4	优化前	优化后
`fork` + `exit` + `waitpid`	338.1 µs	7497 µs	6461 µs
`fork` + `execve` + `waitpid`	2407 µs	43537 µs	22359 µs
└ 其中 execve 内核侧	未测	32.3 ms	**4.5 ms**
上下文切换	10.97 µs	226.8 µs	220.4 µs
双线程 `sched_yield` 交接	6.9 µs	171 µs	112.5 µs
子地址空间退休	未测	3570 µs	410 µs

表 9: 进程与 exec 面的实测。`fork_exec_exit` 收掉 49%，exec 内核侧收掉 86%；`fork_exit` 只降 14%，原因见 5.1 节 的归因

64 MiB 匿名首触	Linux	优化前	优化后
默认 4 KiB 路径，每页	7899 ns/页	1302123 ns/页	**44120 ns/页**（29.5×）
显式大页路径，每页	5683 ns/页	22216 ns/页	8014 ns/页

表 10: 缺页路径的最终位置。默认路径相对自身优化前是 29.5×，相对 Linux 从 165 倍收到 5.6 倍；显式大页路径只差 1.41 倍

显示为 3 050 ns，而撤掉探针后是 1631 ns，也就是 说真实收益是 6.5 倍；其二，`getpid` 的复测区间是 1233–1631 ns，上表取最差值，最好的 1233 ns 对应 2.9 倍。剩下的固定成本构成与“为什么停手” 见 5.1 节。

4.2.3　进程创建与 exec

`fork_exit` 只降 14%，看起来与前面几处改动不成比例：其剩余时间主要落在“切到一个新任务 再切回来”的 11–14 次上下文切换与调度热路径的固定开销上，页表复制只占小头。因此 `fork` 的下一步与上下文切换是同一件事，两者必须一起做。

4.2.4　缺页与地址空间

分档看“成本不再随区域膨胀”这件事最直观（ns/页）：

4.2.5　文件读路径

同一份文件三种分块方式（4 KiB、64 KiB、`md5sum` 默认）读出的校验和完全一致，且与在 主机侧从板子根分区直接导出的同一文件逐字节相同。每轮换一块新 mmap 缓冲时，整轮 803 KB 被

区域	优化前	优化后（索引）	优化后（窗口）
1 MiB	154179	168918	134962
4 MiB	307024	151250	63939
16 MiB	587627	153875	57658
64 MiB	1302123	162213	**44120**

表 11: 优化前每页成本随区域线性上升（154 µs → 1 302 µs）；修掉页索引后四条基本持平，窗口批量物化再整体下移一档

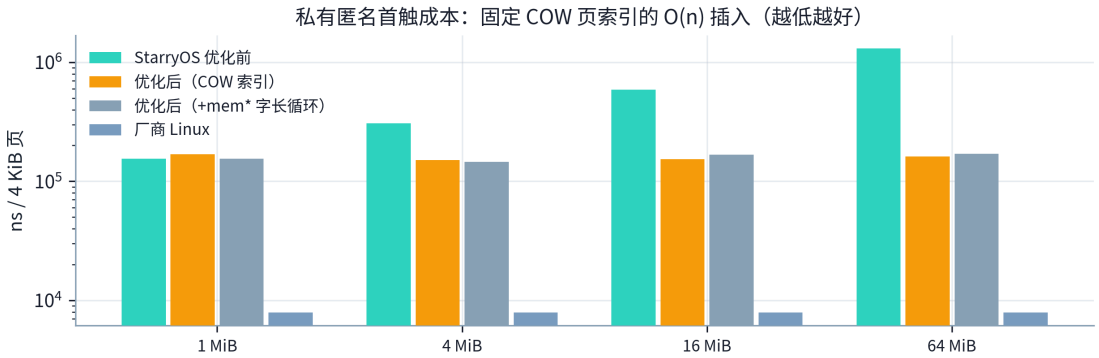


图 2: 优化前/后的首触成本随区域大小的变化，以及与 Linux 的对照。优化前四条随区域线性上升，优化后四条变平（对数轴）

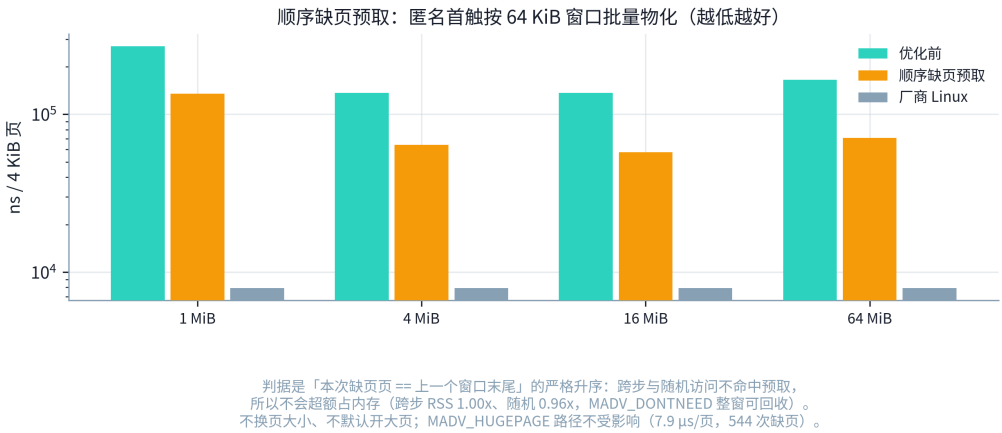


图 3: 顺序缺页预取的同板冷启动受控 A/B（两遍均值）。四种区域大小一致下降约 2.0–2.4 倍，显式大页路径不变

拆成三段：`mmap` 1.5–1.8 µs/页、读（首触 + 拷贝）从 49.68 µs/页降到 44.55 µs/页、`munmap` 从 29.51 µs/页降到 23.39 µs/页， 整轮合计从 80.7 µs/页降到 69.75 µs/页。

4.2.6　存储写回与元数据

吞吐提升有一条必须写清的边界：**页缓存容量把吞吐提了 17.6 倍，但“写完 + `fsync`”的端到端时间几乎不变**。因为 8 MiB 现在一次性回写，而这块 SD 卡约 1 MiB/s 的顺序写速度才是真正的

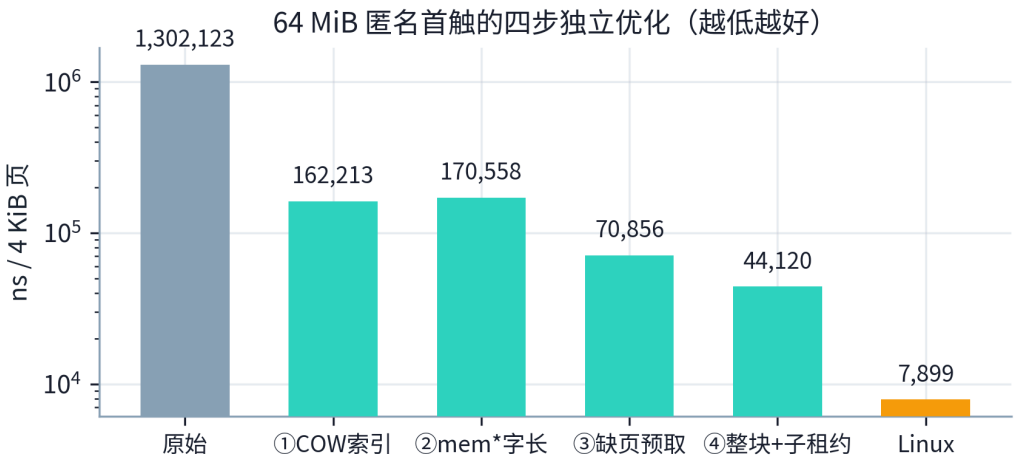


图 4: 64 MiB 匿名首触的逐级优化历程，以及与 Linux 的对照。四个台阶分别是页索引、字长内存操作，以及窗口批量物化里的“窗口预取”与“帧整块 + 子租约”两步（对数轴，越低越好）

指标	Linux 5.10.4	优化前	优化后
缓存命中读（warm）	671.6 MB/s	374 MB/s	474 MB/s
缓存命中读（fresh）	271.1 MB/s	50.2 MB/s	**62.8 MB/s**
单次大读 803 KB	277.2 MB/s	60.9 MB/s	76.2 MB/s
ext4 `open`+`read`(1 KiB)+`close`	42 µs	10320 µs	454 µs

表 12: 读路径的最终位置。`open`+`read`+`close` 改善 22 倍，读吞吐改善约 1.25 倍；fresh 一列仍差 4.3 倍，差距在每页固定开销上

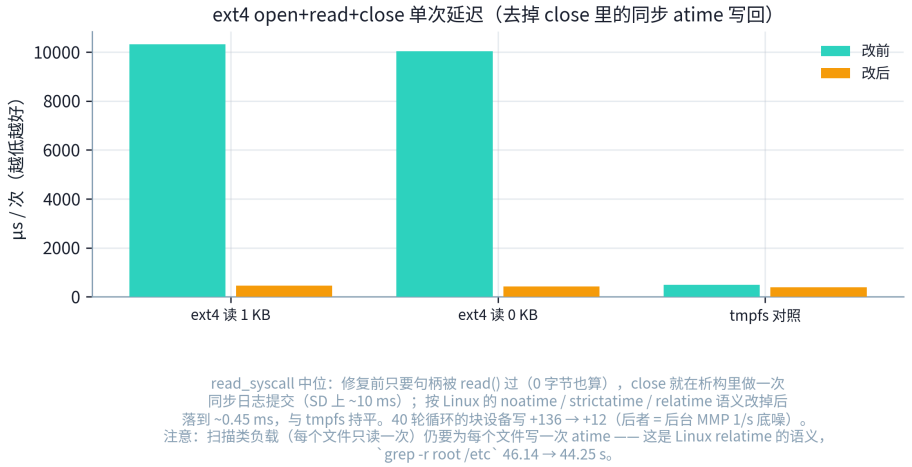


图 5: ext4 `open`+`read`+`close` 的中位耗时（对数轴）：优化前 10 320 µs、优化后 454 µs、同板 Linux 42 µs

底——上限调到 20 MiB 档实测反而只有 1.0–1.4 MiB/s。所以这一族解决的是“每次小批量回写带来 的额外事务与抖动”，不是“卡本身慢”。

8 MiB 档，`fsync` 耗时	Linux ms	优化前 ms	优化后 ms
扇区写（512 B）	814	7 961	1 050
页写（4 KiB）	790	7961	**931**
硬件最大块（1 MiB）	857	7 636	926
规划器切分（1 MiB）	793	7 754	934

表 13: 写回批量化前后的 `fsync` 耗时。四个档位全部落到与 Linux 同一水平（±20%），不再有“档位越大越慢”的现象

指标	Linux 5.10.4	优化前	优化后
8 MiB 顺序写 + `fsync`	790 ms	7961 ms	**931 ms**
8 MiB 页缓存顺序写	34 MiB/s	2.41 MiB/s	**42.43 MiB/s**
ext4 `open`+`read`(1 KiB)+`close`	42 µs	10320 µs	**454 µs**
`fsync`(2 MiB)	790 ms	未测	2000 ms

表 14: 存储面的最终位置。写 + `fsync` 差 1.18 倍、顺序写吞吐反超、`open`+`read`+`close` 差 10.8 倍；`fsync`(2 MiB) 仍差 2.5 倍，属未完成项

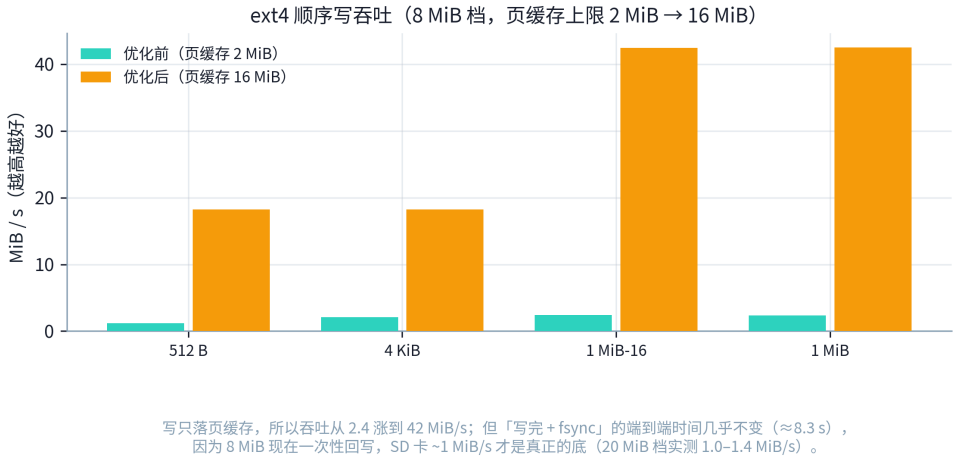


图 6: 页缓存上限提升前后的 ext4 顺序写吞吐（8 MiB 档）。吞吐提高 17.6 倍，但“写完 + `fsync`”的端到端时间不变——底在这块 SD 卡本身

4.2.7　启动时间

启动时间必须分段报，否则会把结论说反。用同一个主机侧探针（同一条串口、同样的逐行时间戳） 把启动切成三段，两侧只在“就绪锚点”上不同——本侧取 shell 提示符，Linux 取 `getty` 的 `login:` 提示符：

这张表给出两个不能混淆的结论：其一，**端到端我方更快**（13.21 s 对 33.2 s），但这主要来自 Linux 自己的脚本重，不能当成“内核更快”的证据；其二，**内核段落后 7.5 倍**（9.01 s 对 1.2 s），这一段全是内核初始化 与设备探测。本轮只动了一处固定等待，上电到用户态标记从 10.81 s 降到 9.61 s、到 shell 可交互从 12.3 s 降到 10.8 s； 其余静默块与不动的理由见 5.1 节。

段	Linux 5.10.4	优化前	归属
U-Boot `fatload`	1.04 s	1.45 s	镜像大小差异：两侧都是约 10.7 MiB/s
`bootm` → 首个用户态输出	1.2 s	**9.01 s**	**这一段才是内核**：内核初始化 + 设备探测
首个用户态 → 可交互提示符	**约 32 s**	4.2 s	rootfs 与 init 脚本
合计（`bootm` → 提示符）	33.2 s	13.21 s	端到端我方更快 2.5×

表 15: 启动分段对照。能归给内核的是中间那一段：本侧 9.01 s 对 Linux 1.20 s，落后 7.5 倍；而端到端本侧更快，主要因为 Linux 的 init 脚本很重

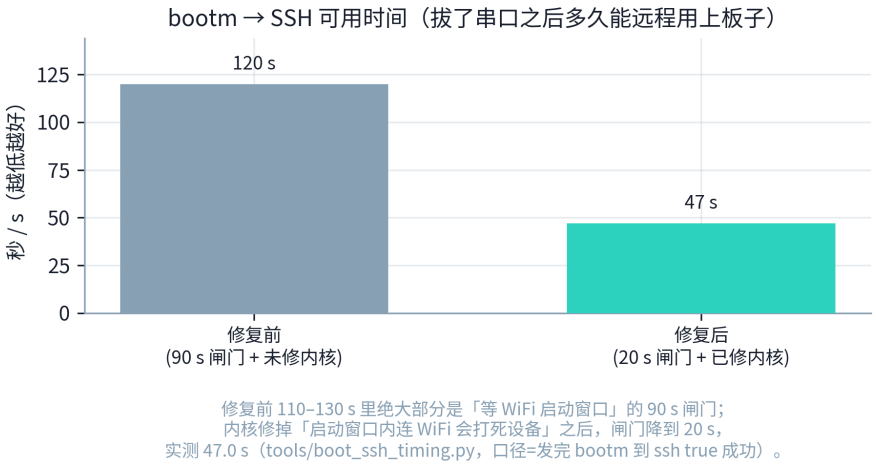


图 7: `bootm` → SSH 可用的时间。优化前绝大部分是“等无线设备启动窗口”的固定闸门（内核修复后闸门从 90 s 降到 20 s）

段	ns/次	说明
陷阱循环整体 `iter`	10 687	用户态进入 → 返回值写回
└ 进入/返回用户态 `enter`	5 558	架构层的一整趟往返
└ 分派与函数体 `handle`	2 654	按调用号查表 + `getpid` 本体
└ ptrace 前置检查 `pre`	264	每次进入都判一次“是否被跟踪”
└ 返回后处理 `post`	439	信号与返回前记账
其它（用户线侧循环、统计口径）	1 772	探针自身与两侧差值

表 16: `getpid` 的分段归因（优化前）。处理体只占 2.65 µs，其余都是路径成本

第 5 章　内核优化的难点与未完成项

5.1　内核优化中的定位方法与难点

这一章记录的是“改动之前发生了什么”：每一族改动都是先被数据指出来的，而这些定位过程 本身就是本项目在方法上的主要产出。把它们写下来还有一重作用——它解释了为什么最终方案 长成现在这样，也让后续接手的人不必重复同样的排除工作。

5.1.1　定位方法：分段计账、标度实验与受控 A/B

三种手法贯穿全部内核优化。第一种是**分段计账**：在内核侧把一条路径切成若干段并累计 耗时，用一个特殊文件（`/proc/fault_attrib`）读出，取“工作负载前后的快照之差”得到每次 调用的平均值。第二种是**标度实验**：固定其它条件、只改一个自变量（区域大小、缓冲区大小、窗口页数），看哪一段的成本随之变化——“随规模变化”的项与“固定”的项对应完全不同的原因。 第三种是**受控 A/B**：同一次上电、交替顺序、各测两遍取均值，用来抵消本板上“启动后第一次 大分配明显更快”这类时间漂移。

这三种手法也解释了为什么本项目的收益集中在“固定开销”上：分段数据反复显示，同一块板上 StarryOS 与 Linux 的差距不在带宽，而在每次操作要付的那一笔固定成本。

5.1.2　系统调用返回路径：一笔 2.17 µs 的冗余刷新

`getpid` 优化前要 10 560 ns，同板 Linux 只要 422.5 ns。更有说服力的是另一组对照：故意传入非法调用号的 `invalid_syscall`（内核里只有“立即返回”这一条路）与 `getpid` 一样 慢——处理体只从当前线程结构里读一个字段，不可能值 10 µs。九个系统调用在优化前呈同一条 水平线，说明它们共享同一笔固定成本。

把最大的一段 `enter` 再拆开，答案落在一个指令上：`fence.i` 占 2 172 ns、真正的寄存器 往返占 2 150 ns、入口校验 267 ns。也就是说，**每次返回用户态都执行一次指令缓存失效**， 它自己值 2.17 µs，并且把此后整条内核路径的指令缓存打冷。而内核本来就已经在真正需要的 两处刷（页变可执行、ptrace 改写正文），返回路径上的这一次是纯冗余。

改动之后 `getpid` 落到 1 631 ns，但还剩下 3.05 µs 的账（含探针开销口径）：

剩下的是同一类东西：单步标志 91 ns、ptrace 速查 102 ns、返回前工作 149 ns、seccomp 88 ns、trace 101 ns。要让它们再快，得把这些分散的布尔判断合并成一次位图检查，属于返回路径的结构性重构，收益上限约 1.5 µs，本轮到此为止。

段	ns/次	说明
返回用户态往返	1 070	架构地板：已无可摘除的冗余
循环内其它	560	采样与记账
分派与函数体	360	查表 + `getpid` 本体
ptrace 前置 + 返回前信号检查	230	每次陷阱都查一遍的开关
用户侧	840	探针循环本身

表 17: 返回路径瘦身之后 `getpid` 的剩余构成。已经没有单项超过 1.1 µs，剩下的是五处“每次陷阱都查一遍”的布尔开关

5.1.3　进程与 exec：账目与两条决定性判据

`fork_exit` 优化前是 7 497 µs。给内核侧与任务侧各加一组分段计数器后，得到的账是：`fork()` 系统调用 4 418 µs（其中 `try_clone` 1 528、首次入队激活 1 724、建线程 591、 其余 575）、子进程 `_exit()` 1 013 µs、子地址空间回收 1 459 µs（由回收线程异步做， 不在 `fork_exit` 的墙钟里）、以及 11–14 次上下文切换（约 2.6–3.2 ms）。

归因给出两条决定性判据，它们把后续方向定死了：其一，**首次入队激活的 1.7 ms 全在守卫析构**——把它拆成三段后，入队 44 µs、收尾 0.6 µs、定时器 10.5 µs，剩下 1 852 µs 全在“从 IRQ 守卫退出时挑下一个任务”。其二，**这 1.7 ms 不是“子进程占用了 CPU”**——让子进程 在 `fork` 返回后先忙等 T ms 再退出，父侧 `fork()` 的耗时完全不随 T 增长。所以它是切换 本身的成本：切到一个全新任务再切回来。

顺带否掉了两个假设：硬件 ASID 是可用的（已经处于标签模式，不存在“每次切换都全量刷 TLB”），以及子地址空间析构并不在 `fork_exit` 的关键路径上。

`exec` 一侧的分段结论是：`exec_load` 31.7 ms 里 `exec_populate` 占 28.3 ms（88%）， 而重定位只占 0.56 ms、ELF 解析 0.05 ms。再往物化里挖又得到两条否证——文件后端的分段 计数全程为 0，说明段映射走的是 COW；一次 51 轮 exec 压力前后的块层读数增量为零，说明 exec 完全不读 SD 卡。

5.1.4　上下文切换：归因清楚了，但没动

一次 `ctx_switch` 优化前是 226.8 µs，Linux 10.97 µs。该指标是“管道写/读系统调用 + 阻塞 + 唤醒 + 一次切换”的整包成本，而非单条切换指令的耗时：

这一族在本轮止步于归因。原因是它已经不是“修一处 bug”的规模：要逼近 Linux 的 10.97 µs， 必须重构调度热路径（空转入口前置判定、入队合并快照、收紧 `settle_current` 与虚拟时间更新），三条都动调度器不变式。本轮先把归因做完——这是后续任何改动的前提。

顺带记录一条**负结果**：把“首次入队立刻抢占”改成 Linux 的 `WF_FORK` 语义（用运行期旋钮在同一镜像上做 A/B），只值 `fork_exit` 0.4%、`fork_exec_exit` 0.9% 的改善。原因是那 1.7 ms 里子进程该做的工作本来就要付，抑制抢占只是把时间从 `fork` 挪到 `waitpid`。

段	µs/次	说明
管道写（含唤醒）	61	其中唤醒 49：选中等待者 0.35、交付 43–47
└ 入队：就绪树插入	13.6	红黑树插入与虚拟时间更新
└ 入队：其余六段	11.7	实体克隆、`settle_current`、`push_class` 等
调度入口	2.1 × 4–6 次	其中约 1/3 是空转：进去发现不需要切换，仍付全额
调度决策	15.6	选取与虚拟时间维护
裸交接	5	地址空间激活 2.0 + CPU 绑定 0.4 + 汇编交接 2.2

表 18: 一次上下文切换的账。**没有单一热点**：十几处 1–15 µs 的固定开销叠加，其中“每次切换要进 4–6 次调度器、1/3 是空转”是可以立刻回收的一块

5.1.5　缺页：从“87.7% 在 prepare”到一个 $O(n^2)$ 的索引

缺页分段的第一层结果把范围收得很窄：`prepare` 占 87.7%，而 TLB 失效只占 0.07%—— 后者直接否掉了“缺页慢是因为刷 TLB”这个常见猜测。再拆 `prepare`，`pending_insert` 占 719 039 ns/页，是整条路径的 58%。

根因是 COW 页索引（一个按物理帧地址排序的 `vec`）在每次插入时都要扫整个索引统计存活 条目，再叠加有序 `vec` 的搬移，整体退化成 $O(n^2)$；成本因此随区域线性膨胀（1 MiB 154 µs → 64 MiB 1 302 µs/页）。修掉之后成本变平，但**搬移**还在：标度实验显示 `pending_insert` 的每页成本仍随区域增长，位置直方图进一步说明插入位置不是两端的 问题（追加只占 21%），而是“一窗 64 页里每一条插入都要把整条尾巴搬一次”，平均每次 搬 1 930 个条目（62 KB），已经贴着这块板的内存带宽。

这一族里最值得记的一处教训是：**把“整段插入”想简单了会把板子挂死**。第一版实现让板子 在启动过程中完全无输出，连软件复位都发不进去，只能人工按复位键。原因是朴素的“整段落位”没有考虑索引里已经存在的过期墓碑条目：如果某个墓碑的物理地址落在这一段区间内部，整段插入之后索引就不再按物理地址有序，而后续的插入与摘除都靠二分查找定位，于是从“插入慢”变成“状态错乱”。重新实现时的安全设计是三条——整段插入全有或全无、遇到空洞或 区间内墓碑就退回逐页登记、容量按整段预留以免在 IRQ 关闭的临界区里分配内存。

同一族里还发现一处**真正的正确性缺陷**：页索引里已释放帧留下的过期墓碑会遮蔽同址重分配 的新主人，使查询返回“无此身份”，让 fork/COW 在帧回收后走错分支。修复方式是自该位置向前扫过所有仍包含该物理地址的条目、返回第一个活主人（无墓碑时仍只查一条，代价不变）。

5.1.6　读路径：前两条线索为什么只值 10%

缓存命中读优化前的画像是“每页取页两把锁 2.2 µs + 页到暂存 4.3 + 暂存到用户 4.5”。 据此做的两条改动——去掉暂存中转（改成 pin 住页缓存页直接拷给调用方）、把用户内存准备 整段化——分别只把大读吞吐从 374 提到 437、再到 474 MB/s，而“每轮换一块新缓冲”那一列 只从 50.2 走到 51.5 MB/s。也就是说，数据路径与缺页事务的“外壳”都不是瓶颈。

决定性的对照来自同一个探针换不同文件：

探针	中位耗时	说明
`read_syscall /proc/uptime 1 KB`	404 µs	procfs，纯内存
`read_syscall /etc/profile 1 KB`	7777 µs	ext4，连跑两遍都是 7.7–7.8 ms
`read_syscall /bin/busybox 1 KB`	10115 µs	ext4，连跑三遍都是 10.10–10.16 ms
`read_syscall /bin/busybox 0 KB`	10038 µs	**读 0 字节也一样慢**

表 19: 决定性对照。耗时与“读多少字节”无关，与“在哪个文件系统”强相关（差 20 倍），且每次重复都一样（不是冷启动开销）

实验	结果	说明
40 次 shell `exec 3</bin/busybox` 后立即关闭（**不读**）	0.9 ms/次	只 open+close 不慢
`read_syscall /bin/busybox 0 40`（读 0 字节）	10.0 ms/次	触发条件是“`read` 被调用过”
40 轮前后 `/proc/diskstats`	writes **+136**、sectors +1088	约 1 个 inode 块 + 一次日志提交；tmpfs 上增量为 0

表 20: 三条零代码实验。答案是：文件对象析构只要句柄“被读过”（0 字节 `read` 也算）就在 `close` 时同步更新访问时间，而 ext4 的元数据更新末尾直接做一次同步日志提交

项	每页	说明与后续想法
页对象建立 `page_object`	7.3 µs	每页一次 `Arc::new` + 页标识堆分配 → 可把页头内嵌进帧，或做对象池
索引插入（按 run 批量化之后）	约 1 µs	已经贴住内存带宽，继续压需要换数据结构
装页表（`pt.map_page`）	3.8 µs	三级走查；可按叶子表批量安装
帧分配 / 清零	3.9 µs	整块分配后主要是清零，受带宽限制
槽 / 反向映射发布	**未精确量到**	余下 **残差** µs/页（由 40 减 16 再减 5 得到）的嫌疑落在这里：每页一个映射槽 + 一次反向映射更新

表 21: 缺页路径的剩余预算。已量到的四项合计约 16 µs/页；另有约 19 µs/页 尚未精确归因，嫌疑是每页一次的槽与反向映射发布

三条推论把范围收得很窄：与读的数据量无关；ext4 比 procfs 慢 20 倍；不是一次性开销。于是转向“`open+read+close` 里哪一段固定地做了 I/O”。分段计时把 10 ms 钉在文件对象 析构上；随后四轮探针逐一排除 VFS 节点驱逐、目录项与文件节点析构、ext4 inode 析构。 最后用三个“零代码”实验直接指认根因：

这一族还有一处值得记录的实现陷阱：**用墙上时钟判断“访问时间是否过期”在本板上永远成立**。 板上没有 RTC、也没有 NTP，`date` 显示 1970 年，比镜像里文件的 2025/2026 年时间戳还小， 拿它套 `relatime` 判据会永远判成“已过期”，退化成每次都写。最终改用单调时钟，并把“上次持久化时间”记在本来就跨 `open` 存活的页缓存身份里。

5.1.7　其余指标的剩余固定成本

上下文切换与读路径之外，还有两处剩余成本已经被量到具体项上，只是本轮没有动：

假设	实测	结论
缺页慢是因为刷 TLB	TLB 段只占整条路径的 0.07%	不做；直接省掉了一次针对 TLB 的改动
页缓存容量不够，应只回收“够腾位置”的子集	回收掉的本来就是脏页，顺序写下每页只回写一次	不做
缓存注册表裁剪是 $O(n^2)$，改掉就能提速	反复打开同一文件时身份被复用，裁剪本来就不跑；实测无变化	改动保留（消除真实复杂度），但不计入收益
`fork` 慢是因为“首次入队立刻抢占”的调度策略	改成 `WF_FORK` 语义只值 0.4% / 0.9%	不做：那段时间本来就要付，抑制抢占只是把它挪到 `waitpid`
无线链路“传输到 9 MiB 就失效”是驱动缺陷	真因是周期性全局同步写回与并发文件系统读踩踏	按并发约束修复，而不是改数据面
页索引插入可以对整段简单地一并合入	第一版实现让板子在启动时硬挂	回退后重做：全有或全无 + 不确定就退回逐页

表 22: 被实测否掉的六个假设。最后一行是唯一一次把板子挂死的改动，重做后的设计见上一节

`munmap` 一侧同样已经拆到底：整轮 23.39 µs/页 里，清页表 10.5、捕获前像 3.61、摘除映射槽 3.28、其余 4.9。清页表 仍在逐页走查两次，但**这一项必须和“空叶子表回收”一起设计**——页表 crate 里已有的批量清 映射原语不剪空目录，单独换上会让“不断换新地址”的程序持续累积页表页，而项目里还有一个 尚未定位的内存增长问题（见下文），不能只为提速而换。

5.2　被数据否掉的假设

优化过程中有相当一部分工作是“证明某条路不值得走”。下表是六个被实测否掉的假设：

5.3　已经归因清楚、但本轮没有改的项

下表每一项都有完整的归因数据，之所以不做，是因为它们都需要改动核心不变式（调度器、页表结构、返回路径的开关结构），单独立项比夹在其它改动里更安全。

5.4　一条尚未定位清楚的问题

项目过程中出现过一次“内存只减不增”的故障：遍历整个 rootfs 时会触发内核内存耗尽并崩溃，表现为回收队列被永久挂住。当时按“整片地址空间被挂住、内存只增不减”的特征加了定位探针， 并逐一验证了四个候选假设——结果**四个假设全部被实测排除**，根因至今没有确定。

目前的状态是：触发路径已经不再复现（遍历整个 rootfs 不再崩溃，回收队列不增长）；探针留在内核里（`/proc/fault_attrib` 的回收队列字段），一旦再次出现可以直接取到队列长度与 重试标志；与之相关的一处结构性风险已经识别——页表批量清映射的原语不剪空叶子表，单独 换上会让“不断换新地址”的程序持续累积页表页。这正是上文“不能只为提速而换”的原因。

把这件事写进报告，是因为它直接约束了后续两处改动的做法，也因为它是一个**负结果**：四个合理的假设都被数据否掉了，说明真正的机制在别处，不能靠推理补齐。

项	归因结论	为什么留到下一轮
上下文切换 220.4 µs	一次切换要进调度器 4–6 次、约 1/3 是空转；入队与虚拟时间维护合计十几处 1–15 µs 固定开销	要重构调度热路径，三条候选都动调度器不变式
`fork` 的 1.7 ms 首次入队重调度	全在“从 IRQ 守卫退出时挑下一个任务”的析构里，且与子进程是否占用 CPU 无关	属于调度策略语义，需要独立排期与专项回归
读路径 fresh 仍差 62.8 对 271.1 MB/s	每页固定成本：页对象 7.3 µs、装页表 3.8 µs，另有约 19 µs/页 尚未精确归因	先补完那 19 µs 的归因（要挂不按 fork 门控的槽发布探针），再决定改法
`munmap` 清页表 10.5 µs/页	批量原语现成，但它不剪空叶子表	必须与“空叶子表回收”一起设计，否则会持续累积页表页
`getpid` 剩余 3.05 µs	返回路径上散着五处“每次陷阱都查一遍”的布尔开关（合计约 530 ns）	收益上限约 1.5 µs，需要重构返回路径的开关结构
定时器与睡眠抖动	时基本身没问题（累积漂移 0.17%），尾部抖动来自唤醒路径	需要一次性定时器 + 精确截止时间队列，改动面覆盖整个定时器子系统
`fsync`(2 MiB) 差 2.5 倍	每次后端写之后都要等一次屏障，粒度保守	屏障下推直接关系掉电一致性，要做专门的掉电测试
启动内核段 9.01 s	三块静默时间：USB 探测 2.1 s、无线固件 1.5 s、ext4 挂载 0.6 s	都牵动设备初始化顺序；本板曾因“启动窗口内控制设备”整机卡死
模型加载约 3 s	模型文件读取 + 张量解析	已归入读路径余项；预读与内存映射交给运行时属应用层改造

表 23: 本轮未做的九项及其理由。它们都已经有可复现的归因数据，接手时可以直接从“改法”开始

第 6 章　内核优化总结

6.1　内核优化总结

内核这条线只做一件事：把“每次都要付的固定成本”降下来。做完之后，它与 Linux 基线的 相对位置可以概括为四条。

第一，**“每次调用都要付”的固定成本已系统性下降，但还没有到齐**。空系统调用从 25.0 倍 收到 3.9 倍，4 KiB 管道往返从 10.4 倍收到 2.8 倍，exec 从 18.1 倍 收到 9.3 倍，ext4 `open+read+close` 从 246 倍收到 10.8 倍。

第二，**缺页这条最深的坑基本填平**。64 MiB 默认路径从 1302123 ns/页 降到 44120 ns/页（29.5×），与 Linux 的差距从 165 倍收到 5.6 倍，而且成本已经 **不再随区域大小增长**——后者比倍数本身更重要，因为它意味着这条路径可以随负载规模扩展。 这一族的四步改进彼此独立，任何一步都可以单独回退。

第三，**带宽型与总量型指标本来就领先或持平，优化后仍然领先**。8 MiB 页缓存顺序写从 2.41 MiB/s 提到 42.43 MiB/s（Linux 34 MiB/s），8 MiB 写 + `fsync` 从 7961 ms 降到 931 ms（Linux 790 ms）， 冷启动到可交互 shell 为 10.8 s（Linux 约 33.2 s）。这些指标 据此判定，差距来自每次操作的固定成本，而同类带宽指标两侧接近。

第四，**剩下的差距集中在两处，且都已被精确定位但没有动**。一是上下文切换（220.4 µs 对 10.97 µs），根因是调度热路径上十几处 1–15 µs 的固定开销叠加； 二是文件读的每页固定成本（fresh 仍差 62.8 对 271.1 MB/s），根因是每页一次的映射槽与反向映射发布、以及页对象建立。两者都需要改动核心不变式， 因此本轮只做完归因、把方案与前置条件写进 5.1 节，而不是在收尾阶段动它们。

方法上的收获与数字同样重要。这一阶段没有一次收益来自“按经验调优”：指令缓存刷新、页索引 的 $O(n^2)$、`close` 里的同步元数据提交，都是先被分段数据指出来的；而被否掉的六个假设（TLB 失效、页缓存回收策略、注册表裁剪、`WF_FORK` 抢占抑制、无线链路的协议层、 整段插入的朴素实现）同样来自数据。这套“先归因、再改动、每步留回退”的做法，是后续接手 这项工作时最应该继承的部分。